



Universitatea Politehnica Timișoara
Facultatea de Automatică și Calculatoare
Departamentul Automatică și
Informatică Aplicată



CLASIFICAREA SEMNALELOR EEG FOLOSIND REȚELE CONVOLUȚIONALE PENTRU DETERMINAREA STĂRII MENTALE

Proiect de Diplomă

Năsui Alexandru-Andrei

Conducător științific
Ș.l.dr.ing. **Ana Maria DAN**

Timișoara
Iunie, 2020

Cuprins

1	Introducere	2
1.1	Temă. Obiective. Motivație	2
1.2	Soluții existente	5
1.3	Structurare pe capitole	5
2	Studiul teoretic. Tehnologii folosite	6
2.1	Prezentare algoritmi	6
2.2	Arhitectura	6
2.3	Tehnologii folosite	6
2.3.1	Hardware	6
2.3.2	Software	6
3	Prezentarea aplicației	7
3.1	Etape implementare	7
3.1.1	Preluare date	7
3.1.2	Prelucrare date	7
3.1.3	Algoritm	7
3.2	Rezultate	7
4	Concluzii	8

Capitolul 1

Introducere

Ceva despre istoria AI

1.1 Temă. Obiective. Motivație

TODO Edit First Paragraph

Tehnicile de învățare automată urmăresc crearea unor modele matematice bazate pe seturi de date inițiale, denumite *seturi de antrenare (training data)*, care pot generaliza informațiile din acestea, iar mai apoi să prezică răspunsul pentru seturi de date necunoscute.

Învățarea automată este folosită într-o largă gamă de aplicații, precum filtrarea mesajelor e-mail de tip spam de cele autentice, răspunsurile date de către motoarele de căutare, clasificarea celulelor tumorale în benigne sau maligne, recunoașterea facială, recunoașterea diverselor obiecte, recunoașterea limbajului vorbit și scris, și mai nou la conducerea automată a mașinilor.

Cele mai multe tehnici de învățare automată fac parte din una dintre cele trei categorii:

- Învățare supervizată (Supervised Learning)
- Învățare nesupervizată (Unsupervised Learning)
- Învățare cu întărire (Reinforcement Learning)

Învățarea supervizată

Învățarea supervizată, în momentul de față este cea mai răspândită metodă folosită în practică. Principiul din spatele acesteia constând în

construirea unui model matematic, prin diferite tehnici, bazat pe un set de date etichetate. Acest set de date etichetate este alcătuit din înregistrări care reprezintă o corespondență între atribute (intrări) și o clasă (ieșire). Astfel, se urmărește generalizarea acestor corespondențe și posibilitatea prezicerii clasei unei înregistrări care nu aparține de datele folosite la învățare. Unii dintre cei mai folosiți algoritmi de învățare supervizată sunt:

- Arbori de decizie
- Metode de regresie
- Algoritmi genetici
- Rețele neuronale artificiale
- Mașini cu vector suport
- Rețele Bayesiene

Învățarea nesupervizată

Procesul de învățare nesupervizată diferă față de cel amintit anterior prin faptul că acesta folosește un set de date de antrenare neetichetat. Algoritmii primesc doar un set de atribute (date de intrare), ne știind ieșirea asociată acestora. Aceștia caută în aceste date asemănări și deosebiri, bazându-se pe proprietățile statistice a datelor. Printre cele mai răspândite tehnici se numără:

- Tehnici de grupare
 - Grupare ierarhizată
 - Tehnica k-means
- Hărți cu auto-organizare
 - Rețele Kohonen
- Modele Markov cu stări invizibile




Figura 1.1: Diferența dintre modul de funcționare al învățării supervizate și învățării nesupervizate [1]

Învățarea cu întărire

Învățarea cu întărire este o metodă de învățare prin interacțiuni repetate a unui *agent* (*software agent*) cu mediul, cu urmărirea atingerii unui anumit scop (Fig. 1.2). Interacțiunile se bazează pe acțiunile luate de agent la stimulii mediului, pentru care v-a primit o recompensă de la acesta în funcție de beneficiul adus îndeplinirii scopului. Recompensele primite au rolul de a îmbunătăți capacitatea agentului de a lua cea mai bună decizie din starea în care acesta se afla la momentul acțiunii. Scopul pe termen lung al agentului este maximizarea numărului de recompense primite. După repetate interacțiuni cu mediul, capacitatea agentului de a lua decizii bune se va crește, iar drumul acestuia prin mediu va tinde spre optim.




Figura 1.2: Modul de funcționare al învățării cu întărire [2]

Obiective

Această lucrare își propune folosirea rețelelor convoluționale pentru clasificarea a trei clase/stării mentale diferite. Metoda de clasificare se bazează pe reprezentarea informațiilor statistice și spectrale a undelor cerebrale sub forma unor imagini alb-negru. Datele EEG (*Electroencefalograma*) au fost extrase cu ajutorul căștii valabile comercial, Muse 2016. Datele extrase au fost prelucrate și etichetate, rezultând 414 atribute și clasa de care aparțin, neutru, relaxat sau concentrat. După extragerea atributelor, au fost selectate și normalizate în intervalul [0:1] 400 de atribute pentru a putea reprezenta o imagine alb-negru de dimensiunea 20x20. După antrenarea clasificatorului cu aceste imagini, acuratețea acestuia la prezicerea imaginilor care nu se aflau în setul de date de antrenare, a fost de 90%.

1.2 Soluții existente

Apariția unor soluții comerciale *low-cost* non-invazive a făcut posibilă înregistrarea și analiza undele cerebrale în afara domeniului medical [3]. Cu toate că acestea sunt folosite în principal în activități simple de interfațare a creierului cu calculatorul (*BCI - Brain-Computer Interface*), apar tot mai multe studii științifice care folosesc aceste aparate.

EEG-CNN[4]

EEG[5]

TODO_PLACEHOLDER

- Utilizare casca pt clasificare EEG de detectare a starii

Scriu despre articolul de clasificare EEG de la cei care au scris articolul cu CNN

O sa scriu despre articolul cu CNN

O sa mai caut niste detalii

1.3 Structurare pe capitole

Capitolul 2

Studiul teoretic. Tehnologii folosite

2.1 Prezentare algoritmi

2.2 Arhitectura

2.3 Tehnologii folosite

2.3.1 Hardware

2.3.2 Software

Capitolul 3

Prezentarea aplicației

3.1 Etape implementare

3.1.1 Preluare date

3.1.2 Prelucrare date

3.1.3 Algoritm

3.2 Rezultate

Capitolul 4

Concluzii

Bibliografie

- [1] Bin Qian, Jie Su, Zhenyu Wen, Renyu Yang, Albert Zomaya, and Omer Rana. Orchestrating development lifecycle of machine learning based iot applications: A survey. 10 2019.
- [2] Christopher Gatti and M. Embrechts. Reinforcement learning with neural networks: Tricks of the trade. *Studies in Computational Intelligence*, 410:275–310, 01 2013.
- [3] EMOTIV. What is an eeg headset? definition & faqs. <https://www.emotiv.com/glossary/eeg-headset/>.
- [4] Jodie Ashford, Jordan Bird, Felipe Campelo, and Diego Faria. *Classification of EEG Signals Based on Image Representation of Statistical Features*, pages 449–460. 01 2020.
- [5] Jordan Bird, Luis Manso, Eduardo Ribeiro, Aniko Ekart, and Diego Faria. A study on mental state classification using eeg-based brain-machine interface. 09 2018.