



Universitatea Politehnica Timișoara
Facultatea de Automatică și Calculatoare
Departamentul Automatică și
Informatică Aplicată



CLASIFICAREA SEMNALELOR EEG FOLOSIND REȚELE CONVOLUȚIONALE PENTRU DETERMINAREA STĂRII MENTALE

Proiect de Diplomă

Năsui Alexandru-Andrei

Conducător științific
Ș.l.dr.ing. **Ana Maria DAN**

Timișoara
Iunie, 2020

Cuprins

1	Introducere	2
1.1	Tema și obiectivele lucrării	2
1.2	Încadrare temă	2
1.3	Soluții existente	5
1.4	Structurare pe capitole	5
2	Studiul teoretic. Tehnologii folosite	7
2.1	Rețele neuronale	7
2.1.1	Perceptronul	7
2.1.2	Perceptronul multistrat	9
2.1.3	Neuronul	10
2.1.4	Antrenarea rețelelor	12
2.1.5	Funcții de cost	14
2.2	Rețele convoluționale	15
2.3	Undele cerebrale	19
3	Prezentarea aplicației	22
3.1	Etape implementare	23
3.1.1	Achiziție date	23
3.1.2	Extragerea atributelor	25
3.1.3	Arhitectura rețelei	29
3.1.4	Antrenarea rețelei	29
3.1.5	Evaluarea și ajustarea parametrilor	29
3.2	Rezultate	29
4	Concluzii	30

Capitolul 1

Introducere

TODO Ceva despre istoria AI?

1.1 Tema și obiectivele lucrării

Această lucrare își propune folosirea rețelelor convoluționale pentru clasificarea a trei clase/stări mentale diferite. Metoda de clasificare se bazează pe reprezentarea informațiilor statistice și spectrale a undelor cerebrale sub forma unor imagini alb-negru. Datele EEG (*Electroencefalograma*) au fost extrase cu ajutorul căștii valabile comercial, Muse 2016. Datele extrase au fost prelucrate și etichetate, rezultând 414 atribute și clasa de care aparțin, neutru, relaxat sau concentrat. După extragerea atributelor, au fost selectate și normalizate în intervalul $[0, 1]$ 400 de atribute pentru a putea reprezenta o imagine alb-negru de dimensiunea 20×20 . După antrenarea clasificatorului cu aceste imagini, acuratețea acestuia la prezicerea imaginilor care nu se aflau în setul de date de antrenare, a fost de $\approx 90\%$.

1.2 Încadrare temă

TODO Schimba numele secțiunii/împarte-o în mai multe

Tehnicile de învățare automată urmăresc crearea unor modele matematice bazate pe seturi de date inițiale, denumite *seturi de antrenare (training data)*, care pot generaliza informațiile din acestea, iar mai apoi să prezică răspunsul pentru seturi de date necunoscute.

Învățarea automată este folosită într-o largă gamă de aplicații, precum filtrarea mesajelor e-mail de tip spam de cele autentice, răspunsurile date de către motoarele de căutare, clasificarea celulelor tumorale în benigne sau maligne, recunoașterea facială, recunoașterea diverselor obiecte, recunoașterea limbajului vorbit și scris, și mai nou la conducerea automată a mașinilor.

Cele mai multe tehnici de învățare automată fac parte din una dintre cele trei categorii:

- Învățare supervizată (Supervised Learning)
- Învățare nesupervizată (Unsupervised Learning)
- Învățare cu întărire (Reinforcement Learning)

Învățarea supervizată

Învățarea supervizată, în momentul de față este cea mai răspândită metodă folosită în practică. Principiul din spatele acesteia constând în construirea unui model matematic, prin diferite tehnici, bazat pe un set de date etichetate. Acest set de date etichetate este alcătuit din înregistrări care reprezintă o corespondență între atribute (intrări) și o clasă (ieșire). Astfel, se urmărește generalizarea acestor corespondențe și posibilitatea prezicerii clasei unei înregistrări care nu aparține de datele folosite la învățare. Unii dintre cei mai folosiți algoritmi de învățare supervizată sunt:

- Arbori de decizie
- Metode de regresie
- Algoritmi genetici
- Rețele neuronale artificiale
- Mașini cu vector suport
- Rețele Bayesiene

Învățarea nesupervizată

Procesul de învățare nesupervizată diferă față de cel amintit anterior prin faptul că acesta folosește un set de date de antrenare neetichetat.

Algoritmii primesc doar un set de atribute (date de intrare), ne știind ieșirea asociată acestora. Aceștia caută în aceste date asemănări și deosebiri, bazându-se pe proprietățile statistice a datelor. Printre cele mai răspândite tehnici se numără:

- Tehnici de grupare
 - Grupare ierarhizată
 - Tehnica k-means
- Hărți cu auto-organizare
 - Rețele Kohonen
- Modele Markov cu stări invizibile




Figura 1.1: Diferența dintre modul de funcționare al învățării supervizate și învățării nesupervizate [1]

Învățarea cu întărire

Învățarea cu întărire este o metodă de învățare prin interacțiuni repetate a unui *agent* (*software agent*) cu mediul, cu urmărirea atingerii unui anumit scop (Figura 1.2). Interacțiunile se bazează pe acțiunile luate de agent la stimulii mediului, pentru care v-a primit o recompensă de la acesta în funcție de beneficiul adus îndeplinirii scopului. Recompensele primite au rolul de a îmbunătăți capacitatea agentului de a lua cea mai bună decizie din starea în care acesta se afla la momentul acțiunii. Scopul pe termen lung al agentului este maximizarea numărului de recompense primite. După repetate interacțiuni cu mediul, capacitatea agentului de a lua decizii bune se va crește, iar drumul acestuia prin mediu va tinde spre optim.




Figura 1.2: Modul de funcționare al învățării cu întărire [2]

1.3 Soluții existente

Apariția unor soluții comerciale *low-cost* non-invazive a făcut posibilă înregistrarea și analiza undelor cerebrale în afara domeniului medical [3]. În principal, aceste dispozitive sunt folosite în activități simple de interfațare a creierului cu calculatorul (*BCI - Brain-Computer Interface*). Raportul zgomot-semnal util mare și eșantionarea imperfectă reprezentând dezavantajele acestor aparate comparativ cu cele de nivel medical. Acest lucru însă nu a împiedicat apariția a tot mai multor studii care folosesc aceste aparate ca o resursă [4].

EEG[5]

EEG-CNN[6]

TODO_PLACEHOLDER

- Utilizare casca pt clasificare EEG de detectare a starii

Scriu despre articolul de clasificare EEG de la cei care au scris articolul cu CNN

O sa scriu despre articolul cu CNN

1.4 Structurare pe capitole

Lucrarea este structurată după cum urmează. *Capitolul 2* prezintă o introducere a ceea ce înseamnă și modul în care funcționează rețelele neuronale de tipul *feedforward* ca mai apoi să poată fi folosite ca suport în înțelegerea funcționalității rețelelor convoluționale. Vor fi menționate avantajele și prezentate aplicațiile de succes ale acestora. Tot aici, vor fi prezentate bazele undelor cerebrale, ce sunt acestea,

cum funcționează și felul în care pot fi detectate. În *Capitolul 3* este prezentat modul de implementare al soluției împreună cu detaliile tehnice aferente. Explicarea tehnicilor de extragere și prelucrare a datelor, detalii privind arhitectura rețelei folosite și rezultatele produse de aceasta se vor regăsi la finalul acestui capitol. Finalul lucrării conține *Capitolul 4*, care aduce concluzii legate de tema acestei lucrări.

Capitolul 2

Studiul teoretic. Tehnologii folosite

TODO Adauga referintele bibliografice aici, intr-un paragraf [9]

Acest capitol are rolul de a prezenta noțiuni și aspecte fundamentale legate de rețelele convoluționale și undele cerebrale, elemente de bază ale acestei lucrări. În prezentarea rețelelor convoluționale se va porni de la perceptronul simplu, care constituie fundamentul acestor algoritmi, apoi va fi prezentată o rețea alcătuită din perceptroni, iar la final va fi prezentată rețeaua convoluțională, construită cu ajutorul noțiunilor și elementelor provenite de la rețeaua neuronală. Undele cerebrale, ce sunt acestea, cum se formează și ce reprezintă va fi prezentat spre finalul acestui capitol.

2.1 Rețele neuronale

Rețelele neuronale artificiale reprezintă un sistem de calcul inspirat după modelul rețelelor neuronale biologice, atât ca și structură, cât și ca mod de procesare a informației. Neuronul artificial reprezintă unitatea elementară a unei rețele neuronale artificiale. Precum neuronul biologic, care conține dendrite și axioni, neuronul artificial imită această structură prin noduri de intrare și noduri de ieșire.

2.1.1 Perceptronul

Conceptele fundamentale ale neuronului artificial provin din modelul perceptronului introdus de către *Frank Rosenblatt (1958)* [7] pe baza cercetărilor anterioare ale lui *Warren McCulloch* și *Walter Pitts* [8].

Perceptronul primește o serie de valori la intrare, $x_1, x_2, x_3 \dots$, și produce o singură ieșire. Pentru calculul ieșirii, sunt folosite așa numitele *ponderi (weights)*, notate cu w_1, w_2, w_3, \dots , numere reale reprezentând importanța fiecărei intrări în determinarea ieșirii.




Figura 2.1: Reprezentarea grafică a unui perceptron

Astfel, ieșirea perceptronului, este determinată de suma ponderată $\sum_i x_i w_i$ comparată cu o valoare reală numită *prag*. Această comparație reprezintă o funcție pentru determinarea ieșirii y , denumită *funcție de activare*. Matematic, funcția de activare a perceptronului este reprezentată de o formă discretă a funcției *treaptă unitate*, descrisă de ecuația (2.1).

$$y = \begin{cases} 0 & : \sum_i x_i w_i \leq \text{prag} \\ 1 & : \sum_i x_i w_i > \text{prag} \end{cases} \quad (2.1)$$

Putem simplifica modul prin care perceptronii sunt descriși, rescriind $\sum_i x_i w_i$ ca fiind produsul cartezian $x \cdot w$, unde x și w sunt vectori care conțin intrările x_i respectiv ponderile w_i . A doua modificare pe care o putem face este să mutăm termenul *prag* în partea stângă a inegalității, denumindu-l *bias/offset*, $b = -\text{prag}$. Astfel, ecuația (2.1) devine:

$$y = \begin{cases} 0 & : x \cdot w + b \leq 0 \\ 1 & : x \cdot w + b > 0 \end{cases} \quad (2.2)$$

Bias-ul poate fi considerat ca o intrare suplimentară de valoare $x_0 = 1$ și $w_0 = b$ care permite translatarea funcției de activare la stânga sau la dreapta.

2.1.2 Perceptronul multistrat

Prin conectarea mai multor perceptroni rezultă rețeaua numită „perceptronul multistrat” (*Multi-layer Perceptron - MLP*). Aceasta este formată dintr-o succesiune de perceptroni complet conectați, așezați într-un strat de intrare, unul sau mai multe straturi ascunse (*hidden layer*) și un strat de ieșire. Ieșirile unui strat reprezintă intrările pentru stratul următor. Rețeaua care conține mai multe straturi ascunse poartă denumirea de „rețea neuronală adâncă” (*deep neural network*), iar în cazul în care aceasta conține un singur strat ascuns poartă denumirea de „rețea neuronală superficială” (*shallow neural network*). Figura 2.2 prezintă o astfel de rețea.




Figura 2.2: Rețea de tipul perceptron multistrat

Rețeaua prezentată mai sus este de tip *propagare înainte* (*feed-forward*), adică, informația în rețea circulă într-o singură direcție, de la stânga la dreapta. Rezultatul procesării informațiilor de către primul strat de neuroni va reprezenta intrarea pentru stratul al doilea, astfel ieșirile acestuia având o semnificație mai abstractă și complexă comparativ cu primul strat. Cu fiecare strat ascuns adăugat rețelei, nivelul de abstractizare al informației va crește, astfel deciziile luate de rețea devenind tot mai sofisticate.

Limitarea acestui tip de rețea poate fi observată încercând să aplicăm schimbări mici ponderilor w conexiunilor (sau a *bias*-ului) unui strat pentru a obține o schimbare mică a ieșirii rețelei. Analitic, acest lucru se rezumă la următoarea ecuație:

$$\Delta y \approx \sum_i \frac{\partial y}{\partial w_i} \Delta w_i + \frac{\partial y}{\partial b} \Delta b \quad (2.3)$$

În realitate însă acest lucru nu se întâmplă întotdeauna. Aceste mici modificări pot determina schimbarea complet a stării¹, spre exemplu de la 1 la 0. Acest comportament poate declanșa o schimbare foarte complicată și greu de controlat în întreaga rețea.

Limitarea dată de capacitatea perceptronului de clasificare binară, poate fi rezolvată însă folosind un alt tip de funcție de activare.

2.1.3 Neuronul

Neuronul artificial este foarte asemănător cu perceptronul prezentat anterior. Acesta este format dintr-un vector de intrări x , un vector al ponderilor w , un bias b și o ieșire y . Valorile vectorului de intrare x nu sunt însă limitate la valorile 1 sau 0, neuronul sigmoid fiind capabil să proceseze valori reale. Precum x , ieșirea y a neuronului poate lua valori reale. Figura 2.3 prezintă un astfel de neuron.

Neuronul care folosește *funcția sigmoid* ca și funcție de activare, dată de ecuația (2.4), se numește neuron sigmoid și este cel mai simplu tip de neuron artificial datorită proprietăților funcției logistice la derivare².

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \text{ unde } z = w \cdot x + b \quad (2.4)$$

¹Acest lucru poate fi observat în graficul funcției de activare al perceptronului din Figura 2.4

²Derivabilitatea funcțiilor de activare este o cerință în cadrul folosirii algoritmului de antrenare prin back-propagation prezentat în §2.1.4




Figura 2.3: Reprezentarea grafică a unui neuron sigmoid

Analizând graficele din Figura 2.4 putem observa faptul că funcția sigmoid este de fapt o versiune netezită a funcției treaptă unitate. Acest lucru ne asigură că schimbările mici efectuate atât în vectorul ponderilor w cât și în b vor fi reflectate în ieșire și că nu vom avea salturi bruște de la 0 la 1 la ieșirea neuronului. Totuși, modelul perceptronului poate fi simulat folosind funcția sigmoid. Atunci când $z \rightarrow \infty$, $\sigma(z) \approx 1$, iar când $z \rightarrow -\infty$, $\sigma(z) \approx 0$. Folosind astfel de funcții de activare ne ajută să găsim ponderile potrivite mult mai ușor și putem afla felul în care modificările acestora afectează ieșirea.

În general, se folosesc funcții derivabile pe întreg domeniul de definiție, care nu au treceri bruște de la un capăt la altul, pentru a facilita antrenarea rețelei. În practică se mai folosesc funcții precum *tangenta hiperbolică*:

$$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} \quad (2.5)$$

sau *funcția unitate liniară rectificată (ReLU)*:

$$R(z) = \max(0, z) \quad (2.6)$$

Figura 2.4 prezintă graficele diferitor funcții de activare.

Este necesar de menționat faptul că aceste funcții se folosesc în special pentru neuronii aflați în straturile ascunse ale rețelei, stratul de ieșire folosind de obicei funcții logistice pentru clasificări binare și funcția *softmax* pentru clasificări multi-clasă.




Figura 2.4: Funcții de activare

2.1.4 Antrenarea rețelelor

Algoritmul prin care se realizează antrenarea rețelelor de tipul feedforward, poartă denumirea de *algoritm de propagare înapoi (back-propagation)*. Acest algoritm a fost făcut faimos de către David Rumelhart, Geoffrey Hinton, și Ronald Williams în 1986 [11]. Algoritmul constă în modificarea repetată a ponderilor conexiunilor din rețea în încercarea de a minimiza o funcție care reprezintă eroarea dintre rezultatul așteptat și cel obținut. Funcțiile folosite cu scopul de a fi minimizate se numesc *funcții obiectiv* sau *funcții de cost* (§2.1.5).

Ecuatiile algoritmului back-propagation

Algoritmul clasic de back-propagation a fost inițial conceput să rezolve probleme de regresie folosind funcții de activare sigmoide. Totuși, acesta poate fi aplicat și problemelor de clasificare cu sau fără astfel de funcții de activare. Pentru a putea face o descriere matematică asupra modului de funcționare al algoritmului, este necesară folosirea următoarelor notații [9]:

1. C pentru a reprezenta o funcție de cost
2. w_{jk}^l pentru specificarea ponderii conexiunii de la neuronul k în stratul $l - 1$ către neuronul j în stratul l .
3. b_j^l pentru bias-ul neuronului j din stratul l
4. a_j^l pentru activarea neuronului j din stratul l

a_j^l depinde de activarea neuronului din stratul $l - 1$ conform ecuației

$$a_j^l = \sigma\left(\sum_k w_{jk}^l a_k^{l-1} + b_j^l\right) \quad (2.7)$$

unde k reprezintă toți neuronii din stratul $l - 1$. Folosind aceste notații pot fi descrise cele patru ecuații fundamentale ale acestui algoritm:

1. Ecuația pentru determinarea erorii din stratul de ieșire L

$$\delta_j^L = \frac{\partial C}{\partial a_j^L} \sigma'(z_j^L) \quad (2.8)$$

2. Ecuație pentru determinarea erorii din stratul l în raport cu eroarea din stratul $l + 1$

$$\delta^l = ((w^{l+1})^T \delta^{l+1}) \odot \sigma'(z^l) \quad (2.9)$$

3. Ecuație pentru determinarea ratei de schimbare a funcției de cost în funcție de orice bias din rețea

$$\frac{\partial C}{\partial b_j^l} = \delta_j^l \quad (2.10)$$

4. Ecuație pentru determinarea ratei de schimbare a funcției de cost în funcție de orice pondere din rețea

$$\frac{\partial C}{\partial w_{jk}^l} = a_k^{l-1} \delta_j^l \quad (2.11)$$

Aplicarea algoritmului back-propagation

Inițial toți parametrii rețelei (ponderile w și bias-ul b) vor fi inițializați aleator³. Urmează apoi etapa de propagarea înainte a datelor din setul de date de antrenare și a comparării rezultatului prezis în comparație cu cel real. Această eroare se calculează conform ecuației (2.8), iar mai apoi va fi propagată înapoi în rețea, strat cu strat, începând cu stratul $l = L - 1$, conform ecuației (2.9). Parametrii vor fi ajustați în funcție de gradientul funcției de cost conform ecuațiilor (2.10) și (2.11). Gradientul funcției de cost se calculează folosind un algoritm de optimizare, cel mai folosit algoritm împreună cu back-propagation este metoda gradientului (*gradient descent*). Algoritmul se repetă pentru un număr stabilit de pași (aleși experimental) sau până când eroarea δ^L scade sub o valoare impusă. Odată cu finalizarea algoritmului, rețeaua va fi pregătită să proceseze date pe care nu le-a întâlnit în setul folosit la antrenare și să facă predicții asupra acestora.




Figura 2.5: Ilustrarea algoritmului de optimizare gradient descent folosit în back-propagation[12]

2.1.5 Funcții de cost

O funcție de cost este o funcție de forma [9]

$$C(w, b, S^T, E^T) \quad (2.12)$$

³Nu este neapărat ca parametrii rețelei să fie inițializați aleator, existând mai multe metode de inițializare

unde w și b reprezintă parametrii rețelei S^T intrarea unui eșantion de date de antrenare și E^T ieșirea dorită din eșantionul respectiv.

Rezultatul dat de asemenea funcției este un număr care reprezintă performanța rețelei de a face preziceri pe baza modificărilor aduse parametrilor acesteia. Se urmărește prin diferite *tehnici de optimizare* minimizarea acestei funcții, valoarea returnată purtând denumirea de *eroare/cost/loss*. În anumite situații însă, spre exemplu în cazul învățării cu întărire, scopul este de a maximiza această funcție, rezultatul fiind denumit *recompensă*.

Atât funcțiile de cost, cât și tehnicile de optimizare ale acestora trebuie alese în funcție de problema în cauză, neexistând o soluție universal valabilă. Empiric, funcțiile de cost se pot împărți în două categorii:

- **pentru probleme de regresie:** eroarea medie absolută (*L1 loss*), eroarea medie pătratică (*L2 loss*), Huber Loss
- **pentru problemele de clasificare:** funcția de cost logaritmică (*cross-entropy*), categoric cross-entropy, divergența Kullback–Leibler

2.2 Rețele convoluționale

Rețelele convoluționale sunt un tip specific de rețele neuronale adânci inspirate din modul de recunoaștere al tiparelor în cortexul vizual uman. Arhitectura acestor rețele s-a dovedit a fi foarte eficientă atât în clasificarea imaginilor cât și în timpul necesar antrenării acesteia.

Una din primele rețele convoluționale de succes a fost *LeNet5* (1989) [13], după repetate iterații începând cu anul 1988. Această rețea a fost folosită în principal pentru detectarea cifrelor și codurilor poștale.

În ziua de astăzi rețelele neuronale convoluționale sunt folosite în diverse aplicații, predominant fiind cele pe baza analizei imaginilor, precum detectarea și recunoașterea obiectelor din seturi de date cu mii de categorii, de exemplu *VGGNet* [14] pe setul de date *ImageNet*, determinarea profunzimii scenelor din imaginile video 2D [15], practic imitând principiul *LIDAR*⁴, segmentarea obiectelor din scenă (*semantic segmentation*). Rețelele convoluționale și-au găsit folosința și în

⁴Light Detection And Ranging - reprezintă un sistem similar de funcționare cu radar-ul, care utilizează laser-ul pentru a afla distanța până la țintă

aplicații care nu implică în mod direct imagini, cum ar fi procesarea limbajului natural sau clasificarea evenimentelor audio [16].

Arhitectura

Structura unei rețele convoluționale este formată din două părți. Partea convoluțională, compusă din stratul de convoluție cu funcția de activare aplicată ieșirii acestuia și stratul de reducere a dimensionalității. A doua parte a structurii este partea de clasificare alcătuită din straturi de neuroni complet conectați asemenea rețelei MLP prezentate în §2.1.2. Figura 2.6 prezintă o astfel de arhitectură.

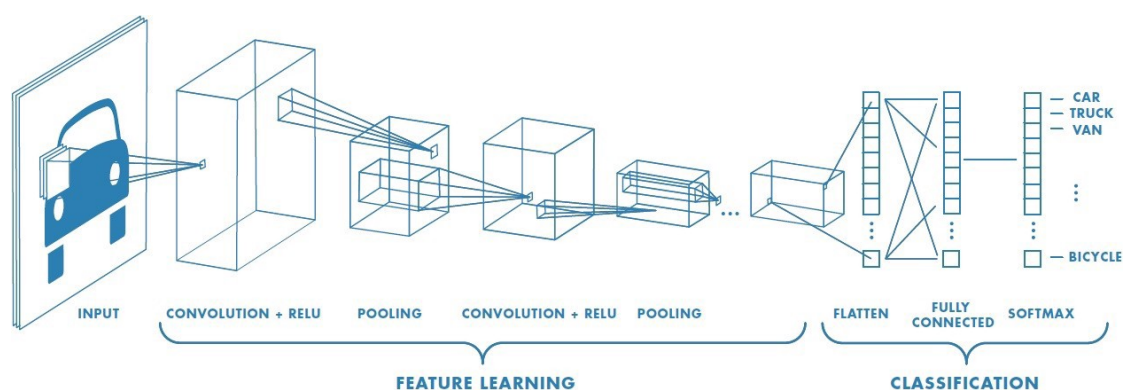


Figura 2.6: Arhitectura generală a unei rețele convoluționale

Straturile de convoluție

Rețelele convoluționale sunt denumite după operația centrală acestora, operația de convoluție. Matematic, operația de convoluție reprezintă rezultatul combinării a două funcții pentru a forma o a treia. Această operație poate fi descrisă în varianta discretă în spațiul 2D sub următoarea formă

$$(f * g)[i, j] = \sum \sum f[m, n]g[i - m, j - n] \quad (2.13)$$

În straturile convoluționale, spre deosebire de cele complet conectate, neuronii ascunși din stratul l sunt conectați la un grup localizat de neuroni din stratul $l - 1$ denumit câmp receptor (*receptive field*). Câmpul receptor reprezintă zona în care este aplicat filtrul/nucleul de convoluție asupra matricei de intrare. Crearea

stratului l de neuroni ascunși se realizează aplicând un filtru/nucleu de convoluție de dimensiune $H \times W$, care va fi mutat peste întreaga imagine de intrare pornind din colțul stânga sus și deplasându-se pe orizontală și pe verticală cu un anumit „pas” (*stride*) notat s . În exemplul din Figura 2.7 pasul folosit este de $s = 1$. Se poate observa faptul că odată cu aplicarea operației de convoluție rezultă o reducere a dimensionalității a matricei rezultate. Acest lucru poate fi remediat brodând cu zero-uri (*zero padding*) marginile matricei de intrare.

$$\begin{array}{c}
 \text{A}(4 \times 4) \\
 \begin{array}{|c|c|c|c|}
 \hline
 1 & 1 & 0 & 1 \\
 \hline
 1 & 0 & 0 & 1 \\
 \hline
 0 & 1 & 1 & 0 \\
 \hline
 1 & 1 & 1 & 1 \\
 \hline
 \end{array}
 \end{array}
 \quad
 \begin{array}{c}
 \text{B}(2 \times 2) \\
 \begin{array}{|c|c|}
 \hline
 1 & 0 \\
 \hline
 1 & 1 \\
 \hline
 \end{array}
 \end{array}
 \quad
 =
 \quad
 \begin{array}{c}
 \text{C}(3 \times 3) \\
 \begin{array}{|c|c|c|}
 \hline
 2 & 1 & 1 \\
 \hline
 2 & 2 & 1 \\
 \hline
 2 & 3 & 3 \\
 \hline
 \end{array}
 \end{array}$$

Figura 2.7: Exemplificarea convoluției a două matrici [12]

Asupra rezultatului de convoluție dintre filtru și matricea de intrare se aplică o funcție de activare, care este adesea de tip ReLU, amintită în §2.1.3. Matricea rezultată în urmă operației de convoluție și aplicarea funcției de activare poartă denumirea de hartă de caracteristici (*feature map*) sau hartă de activare (*activation map*).

Un strat de convoluție este alcătuit dintr-o sumedenie de hărți de caracteristici create folosind diferite tipuri de filtre. Fiecare strat adăugat rețelei, va crea hărți care vor captura caracteristici tot mai complexe din imaginea inițială.



Figura 2.8: Filtrele învățate în primul strat de convoluție de către rețeaua AlexNet [17]

Reducerea dimensionalității

Deseori, după stratul de convoluție este aplicat un strat de reducere a dimensionalității (*pooling*), cunoscut și sub numele de subeșantionare. Acesta are rolul de a micșora dimensiunile spațiale ale hărților de caracteristici și de a reduce numărul de parametri antrenabili, dar în același timp de a păstra informațiile esențiale. Tehnicile folosite uzual pentru operația de *pooling* sunt *Average Pooling*, *Max Pooling*, *Sum Pooling*. Aceste tehnici au la bază folosirea unei ferestre de dimensiuni relativ mici (de obicei 2×2), din care vor fi extrase valorile maxime în cazul *Max Pooling*, valorile medii pentru *Average Pooling* și suma tuturor valorilor pentru *Sum Pooling*. Empiric s-a observat faptul că de cele mai multe ori tehnica *Max Pooling* are cele mai bune rezultate. Figura 2.9 exemplifică aplicarea acestei tehnici.

Pooling—Max pooling




Figura 2.9: Exemplificarea aplicării tehnicii Max Pooling [18]

Operațiile de pooling descrise anterior pot fi înlocuite folosind în stratul convoluțional un pas de deplasare al filtrelor mai mare ca 1 sau folosind un strat convoluțional special cu dimensiunea filtrului 1×1 și cu pasul $s > 1$. Această operație poate fi benefică din punct de vedere computațional, deoarece atât operația de convoluție cât și operația de subeșantionare sunt aplicate în același timp însă poate crește dificultatea de antrenare a rețelei datorită creșterii numărului de parametri antrenabili introduși în rețea comparativ cu tehnicile de pooling care nu conțin nici un parametru, sunt operații fixe.

Subeșantionarea folosind operațiile de pooling clasice poate cauza

probleme rețelelor convoluționale prin pierderea informației poziționale ale diferitelor obiecte prezente în imagine. Scopul inițial al introducerii acestui strat a fost de a reduce numărul de parametri ai rețelei, deci reducerea timpului de antrenare a rețelei. Avansuri în dispozitive hardware tot mai puternice a redus nevoia unei astfel de tehnici, astăzi multe arhitecturi înlocuind această metodă de reducere a dimensionalității cu straturi speciale de convoluție precum *Separable Convolutions* și *Dilated Convolutions*.

Stratul complet conectat

Pentru a putea face legătura între straturile convoluționale și clasificatorul final, ieșirea din straturile convoluționale trebuie transformată din dimensiunea $H \times W \times D$, într-un vector coloană $H \times 1$. Această operație poartă denumirea de *aplatizare (flatten)* și este inclusă într-un strat separat denumit *strat de aplatizare (flatten layer)*.

Odată transformată ieșirea sub formă de vector, aceasta este folosită ca intrare, de obicei, pentru rețele neuronale multistrat. Această rețea folosește pe stratul de ieșire funcția de activare *softmax*, care are rolul de a furniza un vector de probabilități cu dimensiunea egală cu numărul claselor, fiecare poziție a vectorului reprezentând o probabilitate pentru clasa aferentă.

Se mai pot folosi în schimbul rețelelor neuronale și alte tehnici de clasificare, precum *mașini cu vectori suport (SVM)*.

2.3 Undele cerebrale

Creierul uman conține miliarde de celule specifice sistemului nervos, înalt specializate, numite *neuroni*, cu capacitatea de a genera, transmite și recepționa semnale electro-chimice. Un neuron este alcătuit din *corp celular*, *dendrite* și *axon* (Fig. 2.10). Legătura dintre mai mulți neuroni se numește *sinapsă* și este realizată între axonul neuronului presinaptic și dendritele sau corpul celular neuronului postsinaptic. În creierul uman, un neuron formează, în medie, aproximativ 7000 de conexiuni sinaptice. Fiecare neuron deține o diferență de potențial în jurul membranei sale numită *potențial local*. În momentul în care tensiunea electrică crește brusc, neuronul generează un puls electro-chimic denumit *potențial de acțiune*, care străbate rapid axonul neuronului activând conexiunile sinaptice ale acestuia.

Neuron Anatomy




Figura 2.10: Anatomia unui neuron tipic [19]

Descărcările electrice repetate și sincronizate ale neuronilor rezultă în așa numitele *unde cerebrale*, cu benzile de frecvență cuprinse între 0.5 - 50 Hz. *Electroencefalografia (EEG)* este tehnica de detectare și înregistrare în timp a activității cerebrale. Aceasta poate fi folosită în două moduri, invaziv sau neinvaziv.

Electroencefalografia invazivă presupune așezarea electrozilor direct pe suprafața creierului. Folosirea acestei metode de înregistrare a undelor cerebrale rezultă în date achiziționate fără zgomot și precise referitor la zona creierului studiată. Dezavantajul este însă marcat de complexitatea metodei, necesitând intervenție chirurgicală cu riscuri mari.

Achiziția undelor cerebrale într-un mod neinvaziv constă în plasarea electrozilor pe scalp, astfel fiind eliminată necesitatea unei operații și a complexității procedurii. Folosind această metodă datele achiziționate vor fi alterate de zgomot produs de contracțiile mușchilor din zona capului, datele având nevoie de preprocesare înainte de a putea fi folosite.

Există cinci tipuri de bază de unde cerebrale, fiecare fiind atribuită o literă grecească, după cum urmează *delta*, *teta*, *alfa*, *beta*, *gamma*. Undele cerebrale se modifică în funcție de activitatea desfășurată și de dispoziție. Însemnătatea acestora este corelată cu locația detectării în creier.

Delta

Undele delta au cea mai scăzută bandă de frecvență dintre toate undele cerebrale, încadrându-se în intervalul 0.5-4 Hz. Se întâlnesc cel mai des în timpul unui somn adânc sau în timpul meditației profunde. Această stare mentală stimulează regenerarea și vindecarea corpului.

Teta

Banda de frecvență caracteristică undelor teta e între 5 și 8 Hz. Adesea, acestea sunt foarte ușor detectabile în momentele în care visăm. Starea mentală teta mai poate fi observată și în momentul unor activități foarte comune, în care procesul de realizare devine automat. Această stare dă naștere unui șir de gândire și idei liber în care creativitatea este sporită.

Alfa

Undele alfa, cu banda de frecvență între 9 și 14 Hz, reprezintă starea de relaxare conștientă. Plimbările prin parc, momentele de relaxare după îndeplinirea unei sarcini, reflecția sau meditația ușoară reprezintă momente în care undele alfa sunt proeminente.

Beta

Undele beta, având banda de frecvență între 15 și 40 Hz, sunt asociate cu activitatea mentală normală. Acestea sunt prezente în momente precum concentrarea asupra unei probleme, învățarea de noi concepte, stare de alertă sau luarea deciziilor. Concret, această stare este caracteristică gândirii active.

Gama

Undele gama au banda de frecvență cea mai înaltă, >40 Hz, fiind asociate cu procesarea simultană a informațiilor din zone diferite ale creierului. Acestea au fost inițial încadrate ca fiind „zgomot cerebral” până când cercetătorii au observat o activitate accentuată a acestora în stări cognitive și concentrație intensă. Modul de generare al acestor unde cerebrale este încă necunoscut, frecvența acestora fiind peste capacitatea de descărcare a neuronilor.

Capitolul 3

Prezentarea aplicației

Note implementare:

1. Diferite incercari de a extrage feateruri
2. Probleme intampinate in asemanarea datelor NEUTRAL si RELAXED
3. Uita-te pe notebooku Licenta_CNN

Scopul lucrării îl constituie folosirea paradigmei învățării automate supervizate, mai precis, utilizarea rețelelor neuronale convoluționale pentru clasificarea a trei stări mentale diferite, și anume: *neutru*, *relaxat* și *concentrat*.

Datele aferente fiecărei stări provin de la un dispozitiv comercial, *Muse 2016*, capabil de a înregistra activitatea cerebrală folosind tehnica de imagistică *EEG (Electroencefalografia)*, neinvazivă. Aceste înregistrări reprezintă activitatea creierului din jurul electrozilor dispusă în timp. Deoarece dispozitivul folosit folosește o tehnică neinvazivă cu electrozi uscați datele finale ale înregistrării conțin zgomot produs de mișcările persoanei, de contracțiile mușchilor sau chiar de clipit. Din aceste motive datele trebuie prelucrate. Este de menționat faptul că nu există o anumită formulă de prelucrare pentru ca datele să fie perfecte pentru etapa de clasificare, metodele folosite în această etapă fiind stabilite adesea empiric. După prelucrarea datelor, urmează un pas de extragere a anumitor attribute/caracteristici statistice și spectrale pe baza cărora vor fi construite imaginile alb-negru. Fiecare imagine va avea o etichetă aferentă clasei din care face parte, neutru, relaxat sau concentrat.

După etapa de prelucrare și etichetare a datelor, urmează pregătirea datelor pentru transformarea acestora sub forma unor

imagini alb-negru. Această etapă include selectarea celor mai relevante 400 de attribute, dintr-un total de 414. Pentru a putea fi folosite ca și componente ale unei imagini alb-negru, este necesară normalizarea datelor în intervalul $[0, 1]$, 0 reprezentând negru, 1 reprezentând alb, orice altă valoare aparținând intervalului reprezentând o nuanță de gri. Imaginile sunt împărțite apoi în diferite seturi, fiecare cu scopul său specific; setul de antrenare, setul de validare și setul de testare. Antrenarea rețelei convoluționale se realizează folosind setul de antrenare și setul de validare pentru evaluarea performanțelor pe parcursul antrenării. În final, setul de testare este folosit pentru a determina performanța rețelei pe date complet noi, rezultând metricile finale, precum acuratețea sau valoarea funcției de cost (*loss*). În cazul rețelei dezvoltate în această lucrare a fost atinsă o acuratețe de $\approx 91.83\%$ cu valoarea funcției de *loss* de ≈ 0.2511 .

În continuarea capitolului, etapele prezentate sumar anterior vor fi detaliate și explicate, urmând ca la finalul capitolului să fie prezentate rezultatele implementării.

3.1 Etape implementare

3.1.1 Achiziție date

Pentru achiziția datelor a fost folosită casca comercial valabilă Muse 2016. Aceasta conține cinci electrozi uscați, unul fiind folosit ca punct de referință, iar ceilalți patru pentru a înregistra semnalele EEG. Electrozii sunt poziționați în locațiile *TP9*, *AF7*, *Fpz*, *AF8*, *TP10*, conform unei versiuni modificate a sistemului internațional 10-20 de poziționare al electrozilor EEG. Electroful *Fpz* este folosit ca electrod de referință. În Figura 3.1 este prezentat aranjamentul electrozilor.

Pentru a diminua zgomotul înregistrat de senzori, pentru fiecare stare au fost alese activități care necesitau o mișcare minimă a persoanei examinate. Citirile datelor de la electrozii *AF7* și *AF8*, fiind situați pe frunte, sunt distorsionate de mișcările generate de clipit. Astfel, pentru a păstra o uniformitate asupra celor trei stări, clipitul nu a fost nici încurajat nici descurajat. Chiar dacă acesta este considerat zgomot, rata de clipire este influențată de starea de concentrare a persoanei, acest lucru fiind util în final pentru algoritmul de clasificare. Totuși, persoanelor examinate le-a fost specificat să nu închidă ochii pe durata unui test.

Pentru determinarea celor trei stări mentale, au fost stabilite trei




Figura 3.1: Versiunea modificată a sistemului internațional 10-20 împreună cu marcajul poziției electrozilor căștii Muse [20]

activități, conform [5]. Pentru înregistrarea stării neutre, participanții au fost îndrumați să păstreze o poziție confortabilă a corpului și o stare mentală echilibrată, nici prea relaxată dar nici prea activă. Înregistrarea stării mentale de relaxare a presupus ca subiecții să asculte o piesă muzicală cu o tonalitate și un tempo scăzut. Acestora le-a fost indicat faptul de a se relaxa complet, atât fizic cât și psihic. Pentru determinarea stării mentale active și concentrate participanții au fost instruiți să joace o variantă a jocului „alba-neagra”, în care un obiect este ascuns sub unul din mai multe pahare, care mai apoi sunt amestecate între ele. Scopul jocului fiind de a identifica paharul care conține obiectul. Pe parcursul jocului, numărul paharelor și viteza cu care acestea se mișcă va crește.

Activitățile au fost desfășurate începând cu starea neutră, urmată de starea de relaxare, iar la final starea de concentrare. Pentru fiecare activitate în parte au fost efectuate două înregistrări ale datelor EEG pe o durată de 65 de secunde. Primele 3 și ultimele 2 secunde fiind șterse ulterior, scopul acestora fiind de a crea o zonă de tranziție. A mai fost

observată și o transmisie cu frecvență variabilă ($\approx 256\text{Hz}$) a datelor de către casca Muse, astfel zonele de tranziție ajutând la uniformizarea datelor. Datele EEG au fost colectate de la 12 persoane, 5 de sex feminin, 7 de sex masculin. În total au fost înregistrate 26 de minute per stare, din care 24 de minute utilizabile. În Figura 3.2 pot fi observate semnalele provenite de la fiecare electrod în parte. Casca oferă posibilitatea de a adăuga un senzor în plus, semnalul acestuia fiind transmis prin canalul RightAUX. Semnalul provenit de la canalul în cauză a fost eliminat deoarece nu avea conectat un senzor, transmițând astfel doar zgomot.




Figura 3.2: Exemplu semnale EEG Muse 2016, extrase folosind librăria MuseLSL [21]

3.1.2 Extragerea atributelor

Etapa de extragere a atributelor are rolul de a crea un set de date bazat pe semnalele EEG înregistrate, cu scopul de a fi cât mai informative pentru scopul algoritmului. Astfel, se elimină informația redundantă și nesemnificativă obiectivului, aducând avantaje precum scăderea timpului de învățare a rețelei și o mai bună generalizare a datelor. În această lucrare, setul de date format din attribute ale semnalului EEG, este alcătuit din două seturi de date formate din attribute statistice respectiv attribute spectrale. Tipurile de attribute

extrase, atât cele statistice cât și cele spectrale, au fost influențate de către lucrările [6] și [5].

Pentru calculul atributelor, semnalul a fost împărțit în „ferestre”, notate w_i , conținând un set de N valori ale semnalului pentru durata de 1 secundă, transmise cu frecvența 256Hz. Ferestrele conțin o suprapunere de 0.5 secunde, astfel $w_1 = [0, 1]$, $w_2 = [0.5, 1.5]$, $w_3 = [1, 2]$, etc. Din fiecare fereastră rezultată au mai fost create, prin împărțirea fiecărei ferestre w_i , jumătăți și sferturi de fereastră. Rezultând astfel w_{h1} și w_{h2} , reprezentând prima respectiv a doua jumătate a ferestrei, fiecare conținând $N/2$ valori, iar w_{q1} , w_{q2} , w_{q3} , w_{q4} reprezentând sferturile ferestrei, fiecare conținând $N/4$ valori.

Atribute statistice

Având aceste ferestre create, pentru fiecare fereastră w_i au fost extrase atribute statistice considerând fie întreaga fereastră, fie jumătățile, fie sferturile. Astfel, pentru fiecare semnal EEG, au fost extrase următoarele atribute:

- Considerând o întreagă fereastră, w :

1. Media valorilor ferestrei

$$\mu = \frac{1}{N} \sum_n^N x_n \quad (3.1)$$

unde x_n reprezintă setul de valori dintr-o fereastră

2. Deviația standard a valorilor

$$\sigma = \sqrt{\frac{1}{N} \sum_n^N (x_n - \mu)^2} \quad (3.2)$$

3. Varianța (dispersia) valorilor

$$\sigma^2 = \frac{1}{N} \sum_n^N (x_n - \mu)^2 \quad (3.3)$$

4. Momentul centrat de ordin 3 (asimetria valorilor)

$$\mu_3 = \frac{1}{N} \sum_n^N (x_n - \mu)^3 \quad (3.4)$$

5. Momentul centrat de ordin 4 (aplatizarea valorilor)

$$\mu_4 = \frac{1}{N} \sum_n^N (x_n - \mu)^4 \quad (3.5)$$

6. Covarianța perechilor de semnale EEG (TP9, AF7, AF8, TP10)

$$\text{cov}(X, Y) = \frac{1}{N} \sum_n^N (x_n - \bar{x})(y_n - \bar{y}) \quad (3.6)$$

unde x_n și y_n reprezintă setul de valori dintr-o fereastră a unui semnal EEG, iar \bar{x} și \bar{y} reprezintă media acestora

7. Valoarea maximă și valoarea minimă a ferestrei

- Considerând jumătățile de fereastră, w_{h1} și w_{h2} :
 1. Diferența dintre media valorilor jumătăților
 2. Diferența dintre deviația standard a valorilor jumătăților
 3. Diferența dintre maximul valorilor jumătăților
 4. Diferența dintre minimul valorilor jumătăților
- Considerând sferturile de fereastră, w_{q1} , w_{q2} , w_{q3} , w_{q4} :
 1. Media valorilor sferturilor de fereastră
 2. Diferența mediilor perechilor de ferestre
 3. Valoarea maximă și valoarea minimă a ferestrelor
 4. Diferența maximelor perechilor de ferestre
 5. Diferența minimelor perechilor de ferestre

La final, a rezultat un total de 174 de attribute statistice.

Atribute spectrale

Comparativ cu attributele statistice, generarea atributelor spectrale a fost făcută doar pe ferestre întregi, w_i . În cadrul extragerii atributelor spectrale a fost efectuată o prelucrare a semnalului înainte de a calcula attributele. Inițial, a fost realizată o centrare a întregului semnalului în jurul valorii 0, iar mai apoi a fost aplicat un filtru trece-jos de tip Chebyshev I (Fig. 3.3), cu frecvența de tăiere de 50Hz.




Figura 3.3: Răspunsul în frecvență a filtrului trece-jos de tip Chebyshev I de ordin 6

Prin această filtrare se păstrează doar banda de frecvență relevantă undelor cerebrale, și anume 1 – 50Hz.

După aplicarea filtrului asupra întregului semnal EEG, a fost calculată Transformata Fourier Discretă (*DFT*), folosind algoritmul *Fast Fourier Transform (FFT)*. Apoi au fost extrase amplitudinile fiecărei componente ale semnalului filtrat, rezultând 50 de attribute per semnal. Ultimele attribute extrase au fost amplitudinile celor mai puternice 10 frecvențe din componența semnalului. În total, au rezultat 260 de attribute.

Combinând cele 174 de attribute statistice cu aceste 260 de attribute spectrale, rezultă un total de 414 attribute. În setul de date format din acestea, se adaugă și clasa fiecărei înregistrări.

3.1.3 Arhitectura rețelei**3.1.4 Antrenarea rețelei****3.1.5 Evaluarea și ajustarea parametrilor****3.2 Rezultate**

Capitolul 4

Concluzii

Bibliografie

- [1] Bin Qian, Jie Su, Zhenyu Wen, Renyu Yang, Albert Zomaya, and Omer Rana. Orchestrating development lifecycle of machine learning based iot applications: A survey. 10 2019.
- [2] Christopher Gatti and M. Embrechts. Reinforcement learning with neural networks: Tricks of the trade. *Studies in Computational Intelligence*, 410:275–310, 01 2013.
- [3] EMOTIV. What is an eeg headset? definition & faqs. <https://www.emotiv.com/glossary/eeg-headset/>. [Online; Accesat 29.04.2020].
- [4] Alejandro Morán and Miguel C. Soriano. Improving the quality of a collective signal in a consumer eeg headset. *PLOS ONE*, 13(5):1–21, 05 2018.
- [5] Jordan Bird, Luis Manso, Eduardo Ribeiro, Aniko Ekart, and Diego Faria. A study on mental state classification using eeg-based brain-machine interface. 09 2018.
- [6] Jodie Ashford, Jordan Bird, Felipe Campelo, and Diego Faria. *Classification of EEG Signals Based on Image Representation of Statistical Features*, pages 449–460. 01 2020.
- [7] F. Rosenblatt. *Principles of neurodynamics: perceptrons and the theory of brain mechanisms*. Report (Cornell Aeronautical Laboratory). Spartan Books, 1962.
- [8] W S McCulloch and W Pitts. A logical calculus of the ideas immanent in nervous activity. *Bull. Math. Biophys.*, 5:115–133, 1943.
- [9] Michael A. Nielsen. Neural networks and deep learning. <http://neuralnetworksanddeeplearning.com/>, 2015. [Online; Accesat 29.04.2020].

- [10] Hassan Hassan, Abdelazim Negm, Mohamed Zahran, and Oliver Saavedra. Assessment of artificial neural network for bathymetry estimation using high resolution satellite imagery in shallow lakes: Case study el burullus lake. *International Water Technology Journal*, 5, 12 2015.
- [11] David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, Oct 1986.
- [12] Mihnea VREJOIU. Rețele neuronale convoluționale, Big Data și Deep Learning în analiza automată de imagini. *Revista Română de Informatică și Automatică*, 29:91–114, 04 2019.
- [13] Y. LeCun, B. Boser, J. S. Denker, D. Henderson, R. E. Howard, W. Hubbard, and L. D. Jackel. Backpropagation applied to handwritten zip code recognition. *Neural Computation*, 1(4):541–551, 1989.
- [14] Karen Simonyan and Andrew Zisserman. Very Deep Convolutional Networks for Large-Scale Image Recognition, 2014.
- [15] Tinghui Zhou, Matthew Brown, Noah Snavely, and David G. Lowe. Unsupervised learning of depth and ego-motion from video. In *CVPR*, 2017.
- [16] Shawn Hershey, Sourish Chaudhuri, Daniel P. W. Ellis, Jort F. Gemmeke, Aren Jansen, Channing Moore, Manoj Plakal, Devin Platt, Rif A. Saurous, Bryan Seybold, Malcolm Slaney, Ron Weiss, and Kevin Wilson. CNN Architectures for Large-Scale Audio Classification. In *International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2017.
- [17] Krizhevsky, Alex and Sutskever, Ilya and Hinton, Geoffrey E. ImageNet Classification with Deep Convolutional Neural Networks. In *Proceedings of the 25th International Conference on Neural Information Processing Systems - Volume 1, NIPS'12*, page 1097–1105, Red Hook, NY, USA, 2012. Curran Associates Inc.
- [18] Craig Will. Does pooling in convolutional networks actually work? <https://principlesofdeeplearning.com/index.php/2018/08/27/is-pooling-dead-in-convolutional-networks/>, 27 2018. [Online; Accesat 27.04.2020].

- [19] Vecteezy. Diagram of neuron anatomy. <https://www.vecteezy.com/vector-art/358962-diagram-of-neuron-anatomy>, 03 2019. [Online; Accesat 01.05.2020].
- [20] Muse. Muse electrode placement. <http://developer.choosemuse.com>. [Online; Accesat 15.05.2020].
- [21] Alexandre Barachant. Muse LSL. <https://github.com/alexandrebarachant/muse-lsl>. [Online; Accesat 20.03.2020].
- [22] Facultatea de Educație Fizică și Sport, Universitatea din Craiova. Introducere in sistemul nervos. https://efs.ucv.ro/pdf/studenti/cursuri_master/note_curs_nervos.pdf, 11 2007. [Online; Accesat 29.04.2020].
- [23] Brainworks. What Are Brainwaves ? Types Of Brain Waves | EEG Sensor And Brain Wave – UK. <https://brainworksneurotherapy.com/what-are-brainwaves>. [Online; Accesat 29.04.2020].
- [24] Scientific American. What is the function of the various brainwaves? <https://www.scientificamerican.com/article/what-is-the-function-of-t-1997-12-22/>, 2018. [Online; Accesat 29.04.2020].